

UNICEUB

Pós-Graduação em Engenharia de Inteligência Artificial

Ateliê Generativo

Fine-tuning de um modelo de difusão com LoRA no estilo da arquitetura modernista de Brasília

Trabalho apresentado à disciplina de Modelos Multimodais

Leonardo Coutinho

Professor: Romes Heriberto

Brasília, julho de 2026

Links do Projeto

- Repositório GitHub: github.com/lramosc1512/atelie-generativo-LeonidIA
- LoRA Config 1 (Hugging Face Hub): huggingface.co/lramosc1512/lora-estilo-brasilia-config1
- LoRA Config 2 (Hugging Face Hub): huggingface.co/lramosc1512/lora-estilo-brasilia-config2
- Hugging Face Space (aplicação publicada): huggingface.co/spaces/lramosc1512/atelie-generativo-brasilia

1. Introdução e Escolha do Estilo

Este relatório documenta o desenvolvimento do projeto Ateliê Generativo, que consistiu no fine-tuning de um modelo Stable Diffusion utilizando a técnica LoRA (Low-Rank Adaptation), especializando-o no estilo visual da arquitetura modernista de Brasília. O projeto foi desenvolvido individualmente.

A escolha do estilo se justifica por três motivos principais. Primeiro, viabilidade prática: por residir em Brasília, foi possível fotografar boa parte do dataset pessoalmente, embora a decisão final tenha priorizado o uso de imagens já disponíveis sob licença aberta. Segundo, força visual: o estilo modernista de Niemeyer e Lúcio Costa tem elementos bem reconhecíveis, como concreto aparente, curvas orgânicas e pilotis, que ajudam o LoRA a aprender mesmo com um dataset pequeno. Terceiro, riqueza para a reflexão ética: fotografar e treinar um modelo sobre patrimônio público projetado por um autor identificável levanta questões genuínas sobre autoria e originalidade, desenvolvidas na Seção 6.

2. Dataset e Proveniência

O dataset final é composto por 50 imagens, cobrindo aproximadamente 15 edificações do Plano Piloto, incluindo o Congresso Nacional, o Palácio do Planalto, a Catedral Metropolitana, o Palácio do Itamaraty, o Palácio da Justiça, o Memorial JK, o Teatro Nacional, o Museu Nacional, a Torre de TV Digital, o Panteão da Pátria, o STF, a Esplanada dos Ministérios e a Ponte JK.

Todas as imagens foram obtidas do Wikimedia Commons sob licenças Creative Commons compatíveis (CC-BY e CC-BY-SA), com proveniência completa documentada em dados/fontes.csv, incluindo URL de origem, autor, licença e data de coleta de cada imagem.

2.1 Metodologia das legendas

As legendas foram geradas com um rascunho automático via BLIP e revisadas manualmente uma a uma. Na revisão, optou-se por manter as legendas específicas ao conteúdo de cada imagem (nome do prédio, elementos visuais concretos como cúpulas e vitrais, hora do dia), evitando repetir adjetivos de estilo genéricos em todas as legendas.

A lógica dessa escolha: como o token `estilo_brasilia`, é o único elemento comum a todas as 50 legendas, ele concentra o aprendizado do padrão visual compartilhado pelo LoRA. Caso termos de estilo fossem repetidos nas legendas, o aprendizado se distribuiria entre o token e essas palavras, exigindo repeti-las no prompt de inferência para reproduzir o estilo com a mesma intensidade. Essa é uma prática consolidada na comunidade de fine-tuning de LoRA, embora não tenha sido testada empiricamente neste projeto com comparação controlada.

3. Metodologia de Treinamento (LoRA)

O treinamento foi realizado com o script oficial `train_text_to_image_lora.py` da biblioteca `diffusers`, no Google Colab (GPU T4), a partir do checkpoint `stable-diffusion-v1-5/stable-diffusion-v1-5`. Foram treinadas duas configurações distintas para permitir comparação:

Parâmetro	Config 1	Config 2	Justificativa
rank	4	8	Rank maior = mais capacidade para capturar detalhes finos do estilo
learning_rate	1e-4	5e-5	Compensa o rank maior com aprendizado mais conservador, reduzindo risco de overfitting
max_train_steps	1000	1500	Mais passos para o rank maior convergir adequadamente

Ambas as configurações usaram `gradient_accumulation_steps=4` (batch efetivo de 4), precisão `mixed_precision="fp16"` para caber na VRAM da T4, e checkpoints salvos a cada 250 passos. Os checkpoints foram salvos diretamente no Google Drive (montado antes do início do treino) para resiliência a desconexões do Colab, além de publicados no Hugging Face Hub ao final de cada treino.

Os model cards de ambos os repositórios no Hugging Face Hub foram completados manualmente, com descrição do estilo, dataset, hiperparâmetros, resultados de avaliação, limitações conhecidas e usos pretendidos, atendendo à exigência do Critério 5 do barema.

4. Resultados da Avaliação

4.1 Grade Comparativa

Foi gerada uma grade comparativa com 6 prompts fixos, cada um renderizado pelos três modelos (base, Config 1 e Config 2) com a mesma seed, isolando o efeito do LoRA. A inspeção visual revelou uma diferença qualitativa relevante entre as configurações: a Config 1 (rank 4) apresentou casos de mistura de identidades entre prédios distintos. Em uma das gerações, por exemplo, o teto curvo do Palácio do Planalto apareceu combinado com a fachada listrada do Itamaraty numa mesma estrutura fisicamente incoerente. A Config 2 (rank 8) não apresentou esse problema nas mesmas condições, produzindo estruturas mais coerentes, ainda que ocasionalmente combinando texturas de prédios diferentes de forma visualmente plausível.

4.2 CLIPScore

O alinhamento semântico entre imagem e prompt foi medido via CLIPScore (`openai/clip-vit-base-patch16`):

Modelo	CLIPScore médio	Por prompt
Base (sem LoRA)	30.43	32.6, 32.1, 31.2, 27.6, 29.4, 29.7
Config 1 (rank 4)	31.45	33.9, 32.4, 28.1, 29.5, 32.1, 32.7
Config 2 (rank 8)	31.38	35.9, 29.9, 28.3, 33.3, 30.6, 30.2

O CLIPScore não diferenciou as duas configurações (31.45 contra 31.38, uma diferença que cabe dentro da margem de ruído esperada para apenas 6 prompts), mesmo com a diferença visual perceptível na coerência

estrutural observada na grade comparativa. Isso mostra uma limitação real da métrica: ela mede o alinhamento semântico geral entre imagem e texto, não a fidelidade estilística fina nem a coerência estrutural. Por isso a avaliação humana e a inspeção visual qualitativa continuam sendo necessárias, e não substituíveis só por uma métrica automática.

4.3 Verificação de Memorização

Foram geradas 10 imagens a partir de legendas do próprio dataset de treino (Config 2), comparadas lado a lado com as imagens originais correspondentes. Nenhum dos 10 pares apresentou reprodução próxima da imagem original: composição, ângulo e iluminação variaram significativamente em todos os casos, indicando generalização adequada em vez de memorização (overfitting).

Um achado à parte: o Panteão da Pátria foi mal capturado pelo modelo nas duas vezes em que apareceu na verificação. As gerações substituíram sua geometria triangular assimétrica característica por formas genéricas, como uma cúpula ou uma praça de pedra. Isso sugere uma possível sub-representação desse prédio no dataset (poucas imagens dele entre as 50 usadas no treino) ou dificuldade do LoRA em aprender geometrias assimétricas incomuns com o rank utilizado.

4.4 Avaliação Humana

A avaliação humana foi conduzida com um formulário cego (Google Forms) contendo 18 imagens (6 prompts × 3 modelos), avaliadas por 8 respondentes externos em escala de 1 a 5 para fidelidade ao estilo e qualidade visual geral. Um respondente atribuiu nota 5 a todas as 36 respostas sem variação (padrão de baixo esforço); os resultados foram calculados com e sem esse respondente, com conclusões equivalentes.

Resultados (média, n=7 após exclusão do respondente de baixo esforço):

Modelo	Fidelidade ao estilo	Qualidade geral
Base (sem LoRA)	3.86	3.45
Config 1 (rank 4)	3.31	2.95
Config 2 (rank 8)	3.74	3.05

A Config 2 superou a Config 1 nas duas métricas, confirmando com dado humano o padrão já observado na grade comparativa. De forma inesperada, o modelo base pontuou mais alto que as duas configurações treinadas. A explicação mais provável é que os prompts de teste descreviam prédios famosos por nome com detalhes visuais explícitos, o que deu ao Stable Diffusion base espaço suficiente para gerar imagens plausíveis usando conhecimento geral, mascarando a contribuição real do LoRA. Essa hipótese é reforçada pelo comportamento observado no pipeline multimodal (Seção 5), onde o LoRA demonstrou contribuição mais visível justamente em temas menos descritivos.

5. Arquitetura do Pipeline Multimodal

A aplicação foi publicada no Hugging Face Spaces (SDK Gradio) com o seguinte fluxo: o usuário digita um tema curto → um LLM (Qwen2.5-0.5B-Instruct) expande o tema em uma descrição visual → o Stable Diffusion, com o LoRA carregado, gera a imagem no estilo modernista de Brasília → um modelo de TTS (Bark-small) narra em áudio a descrição gerada → a interface Gradio exibe prompt, imagem e áudio juntos.

Modelo LoRA publicado no app: Config 2 (rank 8), com base nos resultados qualitativos da Etapa 3. Essa escolha pode ser revista caso a avaliação humana (Seção 4.4) indique preferência pela Config 1.

5.1 Hardware: mudança de política da Hugging Face

Durante o desenvolvimento do projeto, a Hugging Face alterou sua política de Spaces, passando a exigir assinatura paga (PRO, US\$ 9/mês) para o SDK Gradio, uma mudança que não estava prevista no documento original da disciplina, que previa custo zero. Diante do prazo de entrega, optou-se por assinar o PRO, o que também destravou acesso a hardware ZeroGPU (GPU compartilhada sob cota diária), usado no Space em vez da CPU gratuita originalmente prevista.

5.2 Ajustes na etapa de expansão do LLM

Os primeiros testes revelaram que o modelo pequeno (0.5B parâmetros) não seguia instruções abertas de forma confiável: gerava o token de estilo em formato incorreto (maiúsculas, sem vírgula, por vezes duplicado) e, em alguns casos, ignorava completamente o tema informado pelo usuário, produzindo descrições genéricas desconectadas do pedido. Foram aplicadas três correções: (1) troca de instrução aberta por exemplos few-shot, que modelos pequenos seguem de forma mais confiável; (2) normalização do token de estilo via expressão regular tolerante a variações de acentuação e capitalização; (3) inserção literal e garantida do tema do usuário no prompt final, independente do que o LLM gerasse, eliminando a dependência da confiabilidade do modelo pequeno para esse requisito central.

5.3 Testes e limitação observada

Foram testados 5 temas distintos após os ajustes: 'Prédio residencial', 'Catedral', 'Saudade', 'Parque' e 'Casa de bairro nobre'. Três geraram resultados fortemente alinhados ao estilo treinado (Catedral, Casa de bairro nobre, Parque), enquanto um (Saudade) gerou uma cena urbana genérica sem elementos arquitetônicos do estilo. Um padrão observado: temas que já sugerem um substantivo arquitetônico ou concreto tendem a produzir imagens mais fiéis ao estilo modernista treinado, enquanto temas abstratos deixam o LLM gerar descrições de cena (trânsito, multidões) que competem visualmente com os descritores de estilo no prompt. Um ajuste de ordenação, posicionando os descritores de estilo logo após o token em vez de deixá-los no final do prompt, melhorou esse comportamento de forma consistente nos testes seguintes.

Observação colateral: em um dos testes, o LLM mencionou espontaneamente clubes de futebol reais (Flamengo e Botafogo) que não haviam sido pedidos no tema, um exemplo de alucinação típica de modelos de linguagem pequenos, sem impacto prático no funcionamento do pipeline.

6. Reflexão Ética

6.1 Autoria das imagens geradas

A pergunta de quem é o autor de uma imagem gerada por este pipeline não tem resposta simples. Dá para separar pelo menos três camadas de autoria. A primeira é do fotógrafo que registrou o edifício originalmente e disponibilizou a imagem no Wikimedia Commons. A segunda é dos próprios arquitetos, Niemeyer e Lúcio Costa, autores da forma que está sendo reproduzida, mesmo que de forma indireta, pelo modelo. A terceira é minha, como autor deste projeto, nas escolhas técnicas que moldaram o resultado final: quais imagens entraram no dataset, como as legendas foram escritas e revisadas, qual configuração de LoRA foi publicada no aplicativo e como o prompt final é montado.

Não sou autor da arquitetura retratada, isso precisa ficar claro. Mas as escolhas que fiz ao longo do processo, como a curadoria do dataset, a decisão de manter legendas específicas em vez de genéricas e o ajuste de ordenação dos descritores de estilo no prompt, são escolhas autorais reais, mesmo recaindo sobre um material que não me pertence. Isso indica que autoria em modelos generativos é mais bem descrita como algo distribuído em camadas do que como um autor único e facilmente identificável.

6.2 Respeito aos criadores originais

A maior parte das imagens do dataset veio do Wikimedia Commons sob licenças CC-BY e CC-BY-SA, que exigem atribuição ao autor original. Essa atribuição foi cumprida: a lista completa de créditos, com autor, licença e URL de origem de cada imagem, está documentada em dados/fontes.csv.

Um ponto que acho importante deixar exposto, mesmo sem resposta fechada, é a tensão entre a licença share-alike (CC-BY-SA) de parte das imagens de origem e o modelo treinado a partir delas. Se uma imagem foi disponibilizada sob CC-BY-SA, que exige que trabalhos derivados sejam compartilhados sob os mesmos termos, faria sentido que uma imagem gerada por um modelo treinado nela também fosse licenciada dessa forma? Não existe uma resposta jurídica consolidada para isso, em parte porque a legislação de direitos autorais ainda não trata de forma explícita o status de obras derivadas de modelos de IA generativa. Prefiro deixar essa tensão registrada do que forçar uma conclusão que não tenho base sólida para sustentar.

6.3 Vieses observados

Dois achados empíricos deste projeto mostram vieses que vale registrar. O primeiro veio da verificação de memorização (Seção 4.3): o Panteão da Pátria foi mal capturado pelo modelo nas duas vezes em que apareceu no teste, com o LoRA substituindo sua geometria triangular assimétrica por formas genéricas. A explicação mais provável é sub-representação desse edifício específico no dataset, já que ele aparece em poucas das 50 imagens usadas no treino. É um lembrete direto de que um dataset pequeno e desbalanceado replica esse desbalanceamento no comportamento do modelo, mesmo quando o resultado geral parece consistente.

O segundo veio do pipeline multimodal (Seção 5): temas que já sugerem um substantivo arquitetônico, como catedral ou casa, geraram imagens bem alinhadas ao estilo treinado, enquanto um tema abstrato como saudade não produziu nenhum elemento do estilo modernista. Não é exatamente um viés no sentido de discriminação, mas é um viés de competência desigual do sistema, que funciona bem para um tipo de entrada e mal para outro, sem que isso fique evidente para quem está usando o aplicativo sem saber como ele foi treinado.

6.4 Lei nº 9.610/1998 e LGPD

Sobre direitos autorais, a arquitetura retratada neste projeto é obra protegida pela Lei nº 9.610/1998, já que Niemeyer e Lúcio Costa são autores identificáveis de seus respectivos projetos. Ainda assim, o uso de fotografias de espaços públicos disponibilizadas sob licença Creative Commons oferece respaldo legal para o treinamento do modelo, desde que a atribuição exigida pela licença seja respeitada, o que foi feito neste projeto. Também segui a restrição explícita dada pelo professor de não imitar o estilo de um artista vivo, o que me levou a optar por um movimento arquitetônico histórico, e não por um arquiteto contemporâneo em atividade.

Sobre a LGPD, o dataset não contém pessoas identificáveis, já que o recorte é sobre arquitetura e não sobre retratos. Isso reduz consideravelmente o risco de tratamento de dados pessoais sensíveis. Essa não foi uma ausência acidental do problema, mas uma escolha consciente de curadoria: evitar imagens com pessoas em primeiro plano ou identificáveis, justamente para manter o projeto fora dessa zona de risco desde o início.

7. Declaração de Uso de Ferramentas de IA

Em conformidade com a política da disciplina, este projeto contou com o apoio da IA Claude (Anthropic) nas seguintes frentes, permanecendo o autor integralmente responsável pelo conteúdo entregue:

- Etapa 0: estruturação do repositório GitHub e organização das pastas do projeto.
- Notebook 01 (dataset): expansão do exemplo de código do BLIP fornecido no PDF da disciplina (que processava uma única imagem) para um pipeline completo, incluindo loop sobre todas as imagens, fluxo

de revisão manual via CSV e validação automática (token no início da legenda, ausência de legendas vazias, correspondência com fontes.csv).

- Notebook 02 (treino LoRA): construção da etapa de conversão do dataset (fontes.csv/legendas.txt) para o formato imagefolder/metadata.jsonl exigido pelo script oficial train_text_to_image_lora.py, não coberto no PDF da disciplina; definição técnica das duas configurações de LoRA comparadas; e desenho da estratégia de checkpoint direto no Google Drive para resiliência a desconexões do Colab.
- Suporte geral de resolução de problemas ao longo do projeto: conflitos de versão entre bibliotecas (diffusers, torchao, peft), encoding de arquivos CSV, sincronização Git/GitHub, e ajustes de compatibilidade entre torchmetrics e transformers na etapa de avaliação.

Todas as decisões de escopo, interpretação dos resultados e redação final do relatório são de responsabilidade do autor.